

## **Contexto:**

O nosso projeto surge da necessidade de criar um portal onde diferentes organizações ligadas diretamente ou indiretamente com a gestão de portos marítimos publiquem dados relevantes, para que investigadores, stakeholders e decision-makers possam utilizar e visualizar os dados com diferentes vistas.

## **Problemas a resolver:**

- Multiple data source with different results (Dependendo de quem faz a publicação de dados pode haver diferenças na sua nomenclatura como por exemplo o nome das empresas ou de produtos, o que gera problemas ao realizar estatísticas sobre os dados pois pode resultar em conclusões diferentes à realidade.
- Inconsistency in data points (por exemplo aqueles id em que alguns estão na descrição de transporte já outros preenchem no sítio devido o que pode criar confusão pois também existem situações que ambos estão preenchidos com ids diferentes).
- Elementos duplicados: Uma base de dados com grandes dimensões, pode conter dados duplicados, causados por erros humanos na sua inserção e falhas no controle de qualidade. Isto leva ao sobrecarregamento do sistema e reduz a eficiência operacional. O processo de remoção de dados duplicados é geralmente efetuado com recurso a softwares, que identificam dados duplicados e substituem as cópias que tanto podem ser executados no momento de inserção dos dados ou quando estes já estão armazenados na base de dados.
- Missing data (Em alguns data points há elementos em falta )
- O problema mais geral para resolver é a estrutura da base de dados em si, criar tabelas bem estruturadas, views, índices para agilizar o processo de adicionar e obter conteúdo da base de dados.

## **Soluções:**

- Para o problema da falha de dados vamos utilizar um algoritmo de machine learning para preencher esses dados, este algoritmo já foi desenvolvido por um colega nosso do DETI, especialista nesta área (por o nome se soubermos ). Também vamos fazer a detecção de outliers pois apesar deste algoritmo ter uma grande taxa de sucesso (escrever douta maneira) haverá sempre algumas situações em que não será capaz de gerar os dados de maneira certa, isto será feito através de uma data analyses .
- Uma outra maneira de resolver a falha de dados, vai ser através das descrições feitas pelas pessoas que inserem os dados, a partir delas podemos extrair alguma informação que poderá estar em falta no data point.

## **Objetivos:**

- Criar uma nova base de dados bem estruturada, em que cada data point vai ter uma metadata que diz como cada documento foi gerado ,se foi manualmente, por um script ou pelo algoritmo de machine learning, para depois no data analyses podermos realizar uma melhor filtragem de dados.
- Construção de um site/portal para se realizar uma acesso aos dados mais fácil, onde será possível fazer download de dados e dos seus metadados, bem com para ser capaz de ver uma análise de documentos através de gráfico e tabelas (dashboard) ,e a sua proveniência (se estes são por inserção manual ou gerado por ML).
- Criação de mecanismo para detectar inconsistência nos dados (outliers).

## **Ferramentas a utilizar para comunicação:**

- Github Project para fazer a gestão do projeto
- Github para o repositório de dados
- Discord/Slack para discussão da equipa e repositório de documentos.
- Google Docs para partilha de artigos.
- Slack para se comunicar com os orientadores.

## **Milestones:**

M1-25/02/2025

Requirement Gathering, Goals,life cycle objectives, calendar and Roles of Team

M2-11/03/2025

Use Cases, Architecture,Functional and Nonfunctional Requirements

M3-08/04/2025

Prototype,peer evaluation and mid-term presentation with supervisors

M4-27/05/2025

Project presentation, Posters,Video and Final Deployment

**Calendário:****M1- 25/02/2025**

Requirement Gathering, Goals, life cycle objectives, calendar and Roles of Team

T1- Explorar base de dados DQM Original

T2- Exploração de Use Cases

T3- Definição de tecnologias a serem usadas

T4- Desenho da arquitetura

**M2- 11/03/2025**

Use Cases, Architecture, Functional and Nonfunctional Requirements

T5- Criação da BD com metadados

T6- Instalação do DataProv e outras ferramentas

T7- Implementação da API

T8- Implementação de ML para previsão de dados e detecção de outliers

T9- Desenvolvimento da UI

**M3- 08/04/2025**

Prototype, peer evaluation and mid-term presentation with supervisors

T10- Integração do módulo de visualização e análise de metadados

T11- Finalização da UI e dos restantes Use Cases

T12- Deployment

**M4- 27/05/2025**

Project presentation, Posters, Video and Final Deployment

**Related Work sobre proveniência dos dados:**

A proveniência dos dados é fundamental em sistemas de base de dados complexas como o gerenciamento de operações portuárias, a proveniência de dados ajuda a garantir a integridade e transparência dos dados.

A proveniência de Porquê Identifica que dados de entrada contribuíram para os resultados de uma consulta, crucial para entender as fontes das informações e respectivas inter-relações.

A proveniência de Como descreve as transformações que os dados sofreram para chegar ao estado atual, oferecendo uma visão clara sobre os processos aplicados e facilitando a auditoria dos procedimentos.

A proveniência de Onde rastreia a origem exata dos dados dentro do banco, permitindo identificar a fonte original de cada informação, o que é vital para validar a autenticidade e precisão dos dados.