

Componentes principais do W3C PROV

O modelo PROV possui três entidades principais:

Modelagem Relacional (SQL)

Como a base de dados é relacional, pode-se usar tabelas específicas para os conceitos do W3C PROV:

- Entidades (prov:Entity) → Representadas como registros de tabelas de dados.
- Atividades (prov:Activity) → Tabela para operações realizadas (ETL, transformações).
- Agentes (prov:Agent) → Tabela com utilizadores, sistemas, ou processos responsáveis pelos dados, neste caso as outras tabelas com os dados que derivam dela.
- Relações como prov: wasDerivedFrom, prov:used, prov: wasGeneratedBy podem ser armazenadas como chaves estrangeiras[não no nosso caso porque não as há].

Formatos de Representação do w3c prov

O W3C PROV pode ser representado em diferentes formatos:

- PROV-N → Uma notação textual estruturada.
- PROV-JSON → Representação JSON para fácil manipulação.
- PROV-XML → Para interoperabilidade com sistemas baseados em XML.
- PROV-O → Ontologia OWL para representar proveniência no formato RDF.

Como a base de dados é grande, algumas otimizações podem ser úteis:

Indexação Mais eficiente: Criar índices nos atributos mais consultados para search queries mais rápidas.

Representação PROV em JSON/RDF: Se for interoperar com outros sistemas, armazenar proveniência no formato PROV-JSON ou PROV-O (OWL/RDF) pode ser útil.

Quanto aos polinômios e como eles são representados:

Ferramentas e Frameworks Úteis

Se precisar de ferramentas para trabalhar com W3C PROV, aqui estão algumas opções:

- Apache Jena + PROV-O (se estiver a usar RDF e Web Semântica).
- ProvToolbox (para manipulação de PROV em Java).
- Prov Python Library ([prov](#)) → Biblioteca Python para criar e manipular Proveniência W3C PROV.
- Neo4j → Modelar proveniência como um grafo (muito útil para rastreabilidade complexa!).

Análise da Proveniência dos Dados:


A tabela contém:

- prov → Polinômios que representam a proveniência dos dados.
- prov2 → Token que indica se os dados são originais (T), processados por ML (ML) ou extraídos por processamento de texto (C).

A proveniência é representada por uma cadeia de relações entre entidades, similar a um grafo de proveniência, o que se alinha bem com o modelo W3C PROV.

grafo de proveniência:

Exemplo de Grafo de Proveniência



Com base numa entrada de dados da nossa tabela:

Mapeamento para W3C PROV

Podemos modelar os dados no formato W3C PROV, considerando:

Entidades (prov:Entity)

Entidades no W3C PROV representam objetos que podem ser usados ou gerados em um processo. Na sua base de dados, essas entidades incluem:

- Containers (ex: Container ALPU2220618)
- Documentos de transporte (E_julcm_transport_document:JTD458301)
- Cargas individuais (E_julcm_goods_detail:JGD485249)
- Código harmonizado de mercadorias(E_julmd_harmonized_goods:JHG7520)

Atividades (prov:Activity)

Atividades no W3C PROV representam ações que modificam, criam ou utilizam entidades. Na sua base de dados, isso inclui:

- Movimentos de transporte(E_jultosPSA_trans_equip_movement:PSA2332980)
- Chamadas de navios (E_julgn_vessel_call:JVC4891)
- Registro de documentos de transporte (E_julcm_manifest:JM2447)

Agentes (prov:Agent)

Os Agentes são responsáveis por realizar ou influenciar as atividades. Na sua base de dados, podem incluir:

- Companhias de navegação que transportam os containers.
- Sistemas automatizados que geram e processam dados.
- Modelos de Machine Learning, no caso de dados processados automaticamente (prov2 = ML).

Relacionamentos W3C PROV

prov:wasGeneratedBy → Relaciona um dado com a atividade que o criou.

prov:used → Indica que uma entidade foi usada em uma atividade.

prov:wasDerivedFrom → Para rastrear modificações nos dados ao longo do tempo.

Verificação de Integridade

- Se o polinômio de um dado não corresponder ao esperado, significa que houve alteração indevida.
- Exemplo: Implementação de Merkle Trees para comparar polinômios e verificar consistência.

Compressão de Proveniência

- O polinômio pode representar um hash de proveniência, reduzindo o espaço de armazenamento necessário.
- Pode ser útil se o histórico detalhado da proveniência for armazenado em outro sistema.

Interpolação para Reconstrução

- Se parte da proveniência for perdida, os polinômios podem ser usados para tentar reconstruí-la por reverse engineering.